计算机生成图像的光照

原题：Illumination for Computer Generated Pictures

作者：Bui Tuong Phong（裴祥峰），犹他大学

原载：Communications of the ACM，1975 年 6 月，第 18 卷，第 6 期，第 311–317 页

摘要

计算机生成的三维场景图像，其质量取决于在阴极射线管屏幕上绘制物体时采用的明暗处理技术。明暗处理算法又在一定程度上取决于物体的建模方式，而建模方式也决定了隐藏面消除算法。因此，物体建模、明暗处理与隐藏面消除这几类方法之间存在密切联系。本文介绍了若干与不同物体建模方法及相应隐藏面算法相配合的明暗处理技术。在提出一种能够改善生成图像质量、增强真实感的明暗计算规则时，本文同时考虑了人类视觉感知和光学的基本规律。

关键词：计算机图形学；图形显示；明暗处理（shading）；隐藏面消除。

CR 分类：3.26、3.41、8.2。

原文版权说明：© 1975 Association for Computing Machinery, Inc. 原刊允许在非营利条件下全部或部分转载，前提是保留 ACM 版权声明、注明出版物与刊发日期，并说明转载获 ACM 许可。原研究部分受犹他大学计算机科学部及美国国防部高级研究计划局资助，由纽约州 Griffiss 空军基地的 Rome Air Development Center 监督，合同号 F30602-70-C-0300。原刊所列作者地址为：Digital Systems Laboratory, Stanford University, Stanford, CA 94305。

引言

本文讨论几种为实体物体生成带明暗效果的图像的方法。过去十年间，人们开发了许多利用计算机绘制实体物体的系统。设计这些系统时遇到的两个主要问题是：消除物体被遮挡的部分，以及计算物体的明暗。在此之前，大部分研究精力都投入到寻找快速的隐藏面消除算法上。随着这些算法的发展，图像生成程序已变得相当快速，如今我们可以把注意力转向提高图像质量的算法。

在尝试改善合成图像质量时，我们并不指望把物体连同纹理、投射阴影等细节都显示得与真实世界完全一样。我们的目标只是生成足够接近真实物体、具有一定真实感的图像。这要求我们理解人类视觉系统的一些基本性质。与真实场景的照片不同，计算机生成的明暗图像来自一个存储在计算机中的数值模型，它是对物体的客观描述。根据这个模型生成图像后，最终由人类视觉系统进行主观分析。因此，我们追求的是：生成图像尽可能符合人眼对真实物体的主观解释。

计算机系统可以比作一位不直接观察物体、而是根据文字描述作画的画家。不过，画家如果觉得画得不对，还能亲自修正；计算机生成图像时则无法从最终接收者——人类视觉系统——获得关于图像质量的反馈。

由于这里涉及主观感知，我们首先必须确定希望达到何种程度的真实感，并设定具体目标，包括：

1. 实时显示三维物体的动态彩色图像。所谓实时显示系统，是指每秒至少生成 30 帧图像的系统。

2. 表现由光滑曲面构成的物体。

3. 消除或减弱数字采样技术带来的影响。

要实现这些目标，最重要的考虑因素是物体的建模技术。

已有的明暗处理技术

物体建模方法

图像质量直接取决于明暗处理算法的有效性，而明暗处理算法又依赖于物体建模的方法。通常有两种主要的物体描述方式：

1. 利用数学方程定义曲面。

2. 利用平面多边形的拼接来近似曲面。

已有一些系统能够对数学定义的曲面消除被遮挡部分 [1–5]。这些系统可以获得曲面上每一点的精确信息，因而生成的图像通常最为逼真。然而，它们能处理的曲面类型受到限制，而且隐藏面消除和明暗计算都需要大量时间。到目前为止，这类系统通常只考虑用二次曲面片表示的曲面。尽管更高次数的曲面在建模时很有吸引力、有时甚至必不可少，但由于会显著增加隐藏面消除和明暗计算的耗时，迄今尚未纳入普遍的考虑范围。即使只考虑二次曲面，使用这类模型实现实时显示系统也过于昂贵和复杂。

一种表示曲面及任意形状物体的简单方法，是用许多小的平面多边形近似它们。例如，可以像图 1 那样表示圆锥。这种表示方式的优势，是无需像数学曲面方法那样求解高次方程。

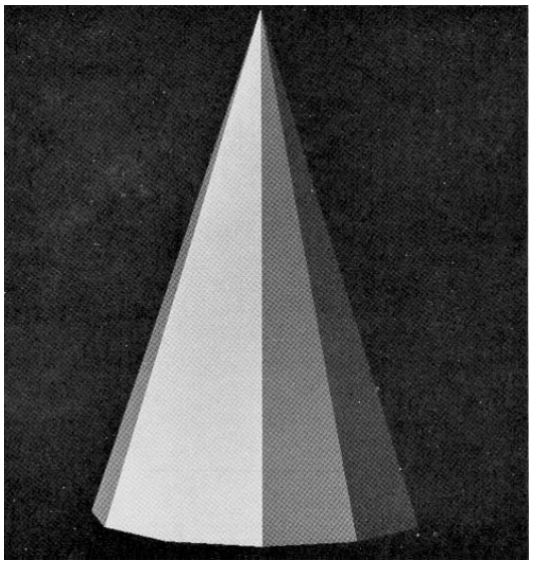


图 1 用平面多边形近似表示的圆锥。

平面近似还能在不限制可表示曲面种类的前提下，把隐藏面计算量降低到合理范围。因此，近期所有旨在开发快速隐藏面算法的尝试，几乎都以这种曲面近似方式为基础。Sutherland 等人在文献 [6] 中归纳并分类了这些算法。下一节将讨论它们对明暗计算方式的影响。

虽然平面近似显著简化了隐藏面消除，却也给逼真图像的生成带来了几个重大问题。其一是轮廓边缘问题：用多边形近似的物体，其外轮廓本身是折线，而不是光滑曲线。其二是如何以逼真的方式为这些多边形计算明暗。本文研究第二个问题；第一个问题由作者与 F. C. Crow 在文献 [7] 中讨论。

隐藏面消除算法的影响

隐藏面算法计算可见信息的顺序，会明显影响明暗处理方式。例如，较早提出这类算法的 Warnock [8] 通过二分细分过程计算显示数据。这意味着生成显示数据的顺序，在很大程度上既不依赖屏幕的扫描顺序，也不依赖多边形在内存中的存储顺序。因此，对曲面物体进行有效的明暗处理就比较困难。

快速隐藏面算法的两项重要进展，分别由 Watkins [9] 和 Newell、Newell、Sancha [10] 提出。Watkins 按扫描线逐行生成显示图像。对于每一条扫描线，算法先确定哪些多边形与之相交，再求出各个多边形的可见片段。这里的片段，是位于该扫描线上的可见窄条，高度为一个屏幕分辨率单位。

Newell、Newell 和 Sancha 则采用另一种办法：使用帧缓冲区，一次绘制一个面。先绘制距离观察者最远的面，最后绘制最近的面，以此解决遮挡问题。每个面都从顶部开始，逐扫描线绘制。

从明暗处理的角度看，这两类算法的共同重要特征是：都按扫描线生成显示物体表面所需的信息。这些信息表现为高度为一个屏幕分辨率单位的片段，随后可以对片段进行明暗计算。对明暗处理而言，它们的主要区别是：（a）片段的生成顺序不同；（b）Watkins 对每个屏幕像素只生成一次结果，而 Newell–Sancha 的算法可能多次覆盖同一个像素。

多面体模型的明暗处理

当使用平面多边形构建物体时，通常使用多边形的法线向量计算明暗。多边形上一点的明暗值，等于该多边形的明暗系数与“多边形法线和入射光方向之间夹角的余弦”之乘积。这个余弦关系在光学中称为“余弦定律”。对于多边形 p，其明暗值可写作：

$$S_p = C_p \cos(i) \quad (1)$$

其中，C_p 是多边形 p 的材料对于特定入射光波长的反射系数，i 是入射角。

这种明暗计算只是对真实物理现象的粗略近似。它没有考虑材料的镜面反射性质——即材料的外表面能够反射光线、形成高光的能力——也忽略了观察者的位置。更严重的缺点是，用它显示光滑曲面时效果很差。余弦定律适合用于本来就由平面组成的物体，例如箱子、建筑物等；但对于汽车车身那样的光滑曲面就不够合适。

这并不意味着我们应当放弃面向多边形的明暗规则，转而另找一套完全不同的曲面规则。近期有关明暗处理的研究表明，只要以式（1）为基础，再对结果进行修改，减轻相邻多边形之间明暗不连续的问题，就能取得显著改善。

1. Warnock 的明暗处理

三维物体投影到阴极射线管屏幕后，深度感会丢失，图像看起来变得平坦。为了恢复深度感，Warnock 模拟了两种现象：

1. 随着光源与物体之间的距离增加，物体反射光的强度减弱。

2. 镜面反射产生的高光。

Warnock 把光源和眼睛放在同一个位置，使明暗函数由两项之和构成：一项是普通的“余弦定律”项，另一项是镜面反射光项。得到的图像具有一些有益特征：例如，空间位置不同但朝向相同的平行面，会呈现不同亮度；直接面向光源的小平面，比略微偏离入射光方向的相邻小平面更亮。

然而，当用多边形近似曲面时，各个面之间的明暗仍然不连续。显示曲面时，这种不连续会破坏原有的光滑感。图 1 清楚地展示了这一点。

2. Newell、Newell 和 Sancha 的明暗处理

Newell、Newell 和 Sancha 提出了一些表现透明度与高光的想法。他们观察真实世界后发现，高光不仅来自入射光源，也可能来自场景中其他物体所反射的光。对于由高反射率材料或透明材料制成的物体，这一点尤其明显。

在 Newell–Sancha 模型中，曲面同样由平面多边形近似。遗憾的是，由于无法改变单个多边形表面不同位置的光照强度，高光的生成能力受到严重限制。图 2 可以看出这个问题。

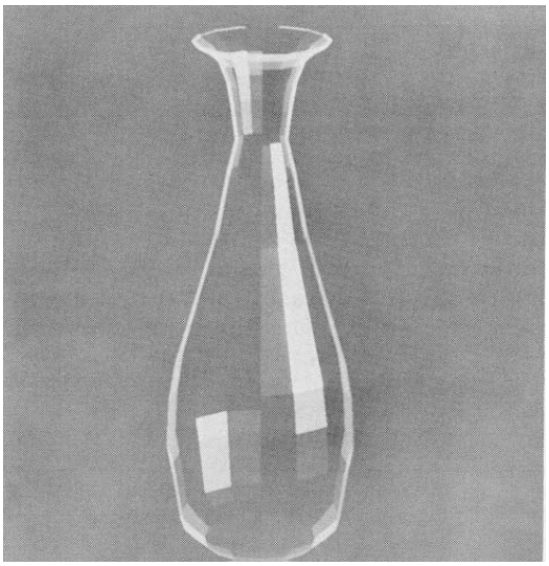


图 2 Newell 等人的明暗处理：透明与高光效果。

3. Gouraud 的明暗处理

Gouraud [11] 在研究如何表现由 Coons 曲面或 Bézier 曲面片构成的曲面物体时，开发了一种曲面明暗处理算法。该算法将曲面片近似为平面多边形面片，并在每个面片的各个顶点计算有关曲面曲率的信息，再由此求出并保存明暗强度。

例如，可以在每个顶点使用式（1）计算强度，此时 i 表示入射光与该顶点的曲面法线之间的夹角。绘制曲面时，沿着每一对相邻顶点之间的边，对顶点明暗强度进行线性插值。曲面内部某一点的明暗值，则通过扫描线与两条边的交点之间再次进行线性插值获得（图 3）。

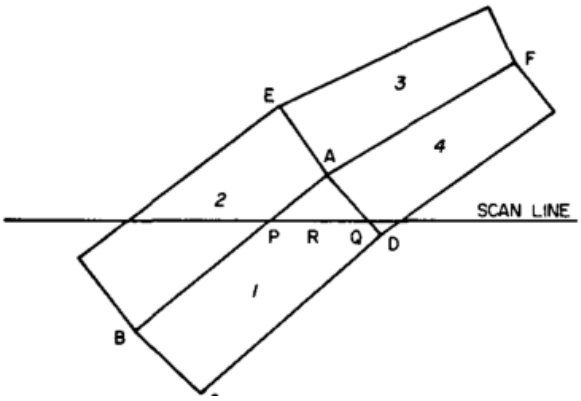


图 3 Gouraud 明暗插值：先沿边插值，再沿扫描线插值。

这种非常简单的方法，使整个曲面的明暗能够连续、渐变；在大多数情况下，它恢复了曲面光滑的视觉效果。图 4 展示了 Gouraud 明暗处理的例子。

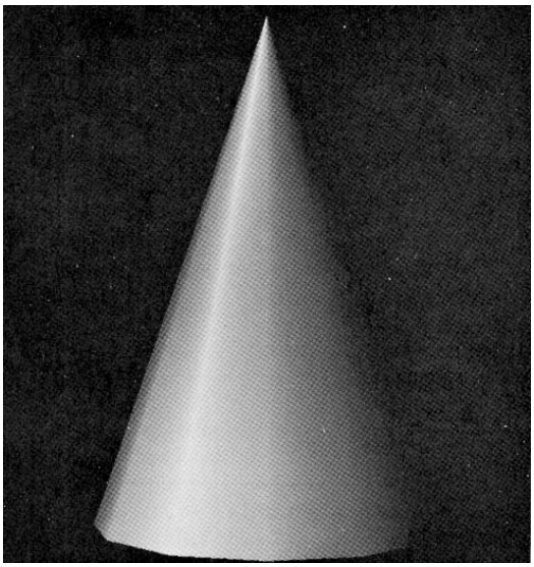


图 4 图 1 的圆锥经过 Gouraud 明暗处理后的外观。

随着 Gouraud 平滑明暗处理技术的出现，计算机生成图像的质量得到显著改善，许多不同类型的物体因此可以相当逼真地显示出来。不过，仍然存在问题，其中之一便是多边形边缘处明显的视觉不连续。

对于镜面反射成分较强的表面，高光的形状经常不恰当，因为它依赖于近似曲面所使用的多边形的位置分布和形状，而不是物体曲面本身的曲率。对于处于运动中的表面（例如计算机动画），描述表面的多边形朝向不断变化，会造成相邻帧之间令人不快的明暗跳变。此外，这些明暗算法并不具有旋转不变性。

下面的情况说明动画中逐帧明暗不连续的问题。假设一个曲面用平面面片近似。物体运动时，所有法线与光照方向垂直的面片都会呈现均匀明暗。到了下一帧，物体运动改变了这些面片相对光线的朝向，于是其表面亮度从一端到另一端连续变化。这样一来，同一表面看起来会在“具有高光”和“明暗均匀”两种状态之间跳变。此外，随着物体转动，高光的位置也无法在相邻帧中保持稳定。

马赫带效应（Mach Band Effect）

与平面近似曲面有关的许多明暗问题，都来自多边形边界上的不连续。人们可能以为，只要把多边形做得更小，就可以避免这些问题。当然，这样做并不理想，因为多边形数量会增加，存储模型的内存需求和隐藏面消除所需时间也都会增加。

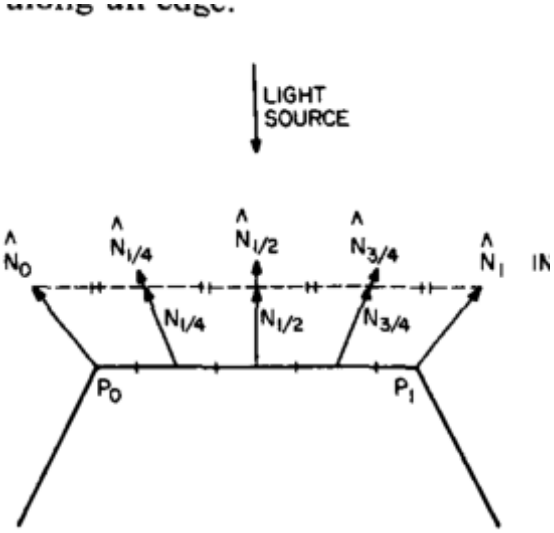


图 5 多边形一条边上某点的法线。

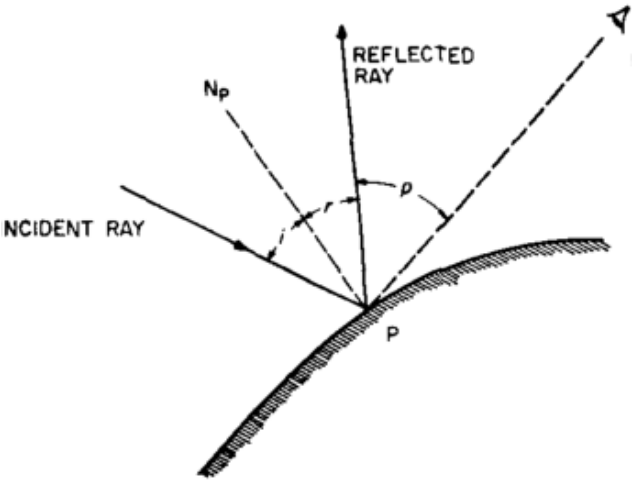


图 6 点 P 的入射光、反射光和观察方向。

不幸的是，受人类视觉感知的影响，缩小多边形的好处并没有想象中那么大。这里起作用的是“马赫带效应”。Mach 提出过以下原则：

> 当一个受照表面的光强只沿一个方向变化时，只要光强曲线相对于横坐标轴出现凹向或凸向的弯曲，相应位置就会分别显得比周围更亮或更暗。——E. Mach，1865 年

只要光强曲线的斜率发生变化，就会出现这种效应。其可察觉程度取决于曲率变化的大小，但这种效应本身始终存在。

如果没有马赫带效应，我们或许可以指望通过缩小多边形来获得准确的明暗处理。然而，人眼会强化多边形边界处的不连续，使边缘附近出现不希望看到的、似乎更加明亮的区域。因此，除非把显示的面片缩小到单个分辨率点，否则增加面片数量并不能解决问题。

Gouraud 方法通过在顶点之间线性插值明暗值，消除了明暗函数本身的跳变，但当明暗函数斜率发生变化时，马赫带效应仍然可见。图 4 就能看到这种情况。马赫带效应在边缘处造成的主观亮度不连续，最终破坏了曲面的光滑外观。

因此，本文提出一种更好的明暗规则，用于显示由平面多边形描述的曲面。这项新技术要求计算显示表面上每一点的法线，因此计算开销高于 Gouraud 方法；但生成图像的质量与高光位置的准确性都得到了很大改善。

采用物理模型

镜面反射

如果计算机合成图像的明暗处理目标是模拟真实的物体，那么明暗模型就应在某种程度上模仿真实的物理光照情况。显然，式（1）没有做到这一点。如前所述，它完全忽略了观察者的位置及物体的镜面反射性质。即便引入 Gouraud 的改进、显著提高明暗质量，这两项性质仍被忽略。

要考虑物体的镜面反射性质和观察者位置，第一步是确定表面上每个待着色点的法线；也就是说，要为光栅显示中的每个像素在物体表面对应的位置确定法线。只有知道法线，才能获得反射光线的方向信息；也只有这样，才能模拟物体的镜面反射性质。

然而，前面的讨论表明，我们的多面体模型只在多边形的顶点提供法线信息。因此，改进明暗模型的第一步，就是设法为每个光栅单位确定表面法线。

曲面上某点法线的计算

每个顶点的法线可以采用 Gouraud 所述的方法之一进行近似 [11]。接下来，需要定义多边形边上的点以及多边形内部点的表面法线。

对于多边形模型的一条边，其上某一点的法线，可以通过对该边两个端点的法线做线性插值得到。如图 5 所示，对于位于 P_0 与 P_1 两个顶点之间的点，其法线 N_t 可计算为：

$$N_t = t\,N_1 + (1 - t)\,N_0 \quad (2)$$

其中，$t = 0$ 时对应 N_0，$t = 1$ 时对应 N_1。

多边形内部某一点的法线，可以用与 Gouraud 方法计算该点明暗值相同的方式得到。具体来说，在经过该点的扫描平面与多边形的两条边相交后，取两个交点处的法线，对它们进行线性插值，便得到该点可见表面的法线。注意，这种一般位置的表面法线与顶点法线呈二次关系。

得到某一点的近似法线后，便由明暗函数确定该点的明暗值。

明暗函数模型

在计算机图形学中，明暗函数是一种函数：它根据光源的特征、物体的特征和观察者的位置，给出物体表面各点的强度值。

考虑到眼睛所接收的光，一部分来自入射光的漫反射，另一部分来自入射光的镜面反射，物体上 P 点（图 6）的明暗值可以计算为：

$$S_p = C_p\,[\cos(i)(1 - d) + d] + W(i)[\cos(s)]^n \quad (3)$$

式中各符号的含义如下：

1. C_p：物体在 P 点针对某个波长的反射系数。
2. i：入射角。

3. d：环境漫反射系数。

4. W(i)：随入射角 i 变化的函数，表示镜面反射光相对于入射光的比例。

5. s：反射光方向与视线方向之间的夹角。

6. n：用于描述材料镜面反射特征的幂指数。

函数 W(i) 与指数 n 表达了材料的镜面反射特征。对于反射性很强的材料，W(i) 和 n 都比较大。W(i) 的取值范围为 10% 至 80%，n 的范围为 1 至 10。这些值是为获得合适画面而凭经验调整的，并不声称具有物理上的严格依据。

为简化模型及式（3）中 cos(i)、cos(s) 两项的计算，作者作出两个假设：

1. 光源位于无穷远处，也就是说，光线互相平行。

2. 眼睛同样位于无穷远处。

在这两个假设下，式（3）中的余弦项可以重写为：

$$\cos(i) = (k \cdot N_p) / |N_p|; \quad \cos(s) = (u \cdot R_p) / |R_p|$$

其中 k、u 分别是沿光线方向和视线方向的单位向量，N_p 是 P 点的法线向量，R_p 是 P 点反射光的方向向量。

量 $(k \cdot N_p)/|N_p|$ 可以理解为：归一化法线向量在平行于光线方向的轴上的投影。如果 $|N_p| = 1$，那么在某一坐标轴平行于光线方向的坐标系中，这个量就是 N_p 的一个分量。同样的思路下，$(u \cdot R_p)/|R_p|$ 也可以直接从法线向量求得，方法如下。

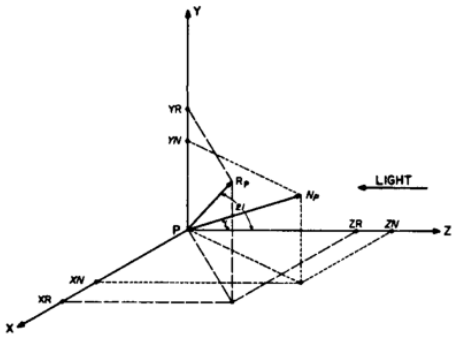


图 7(a) 确定反射光方向。

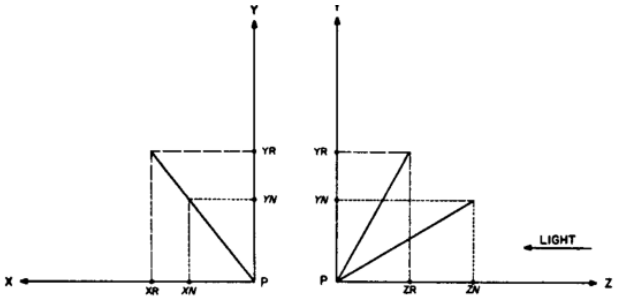


图 7(b) 反射方向与法线的投影。

考虑一个笛卡尔坐标系：原点位于 P 点，z 轴与光线平行但方向相反，如图 7(a) 所示。对模型作如下假设：

1. 归一化法线向量 N_p 与 z 轴夹角为 i，反射光向量 R_p 与同一条轴夹角为 2i。
2. 明暗计算只考虑小于或等于 90° 的入射角。入射角更大时，意味着光源位于正面表面的背后。如果希望显示可见的背面，可以假定法线总是指向光源。
3. 如果 k 是沿 PZ 轴的单位向量，那么根据简单的几何关系，k、N_p 和 R_p 三个向量共面。
4. N_p 和 R_p 都是单位长度向量。

由假设（3）可知，N_p 和 R_p 在 PX–PY 平面上的投影落在同一条直线上（图 7(b)）。因此：

$$X_r / Y_r = X_n / Y_n \quad (4)$$

其中，X_r、Y_r 分别是 R_p 在 x、y 方向的分量；X_n、Y_n 分别是 N_p 在 x、y 方向的分量。

由假设（1）和（2），N_p 的 z 分量为：

$$Z_n = \cos(i),\quad 0 \leqslant i \leqslant 90° \quad (5)$$

通过简单的三角恒等变换，可以得到：

$$Z_r = \cos(2i) = 2[\cos(i)]^2 - 1 = 2Z_n{}^2 - 1 \quad (6)$$

$$X_r{}^2 + Y_r{}^2 = [\sin(2i)]^2 = 1 - [\cos(2i)]^2 \quad (7)$$

由式（4）与式（7），可得：

$$X_r = 2\,Z_n\,X_n;\quad Y_r = 2\,Z_n\,Y_n;\quad 0 \leqslant Z_n \leqslant 1$$

这样一来，R_p 在光源坐标系中的三个分量就都已知了。通过一次简单的点积，可以求出 R_p 在观察者坐标系 z 轴上的投影。R_p 沿视线方向轴的分量，正是反射光与视线之间夹角的余弦。随后便可以用这个余弦值来模拟镜面反射。

对于表面上的每一个点，通过法线方向直接求得反射光方向，比先在各顶点计算反射光向量、再像插值法线那样插值反射光向量更好。这种方法更快，也比插值方案需要更少的存储空间。

使用上述方法时，一点的明暗是根据该点近似法线的朝向计算的，而不是对顶点明暗值进行线性插值。因此，它能更好地近似曲面弯曲的特征，并正确显示模拟镜面反射产生的高光。图 8、图 9 展示了这种明暗处理技术的应用实例。图 10 则将使用这项技术生成的图像与真实物体的照片进行比较。

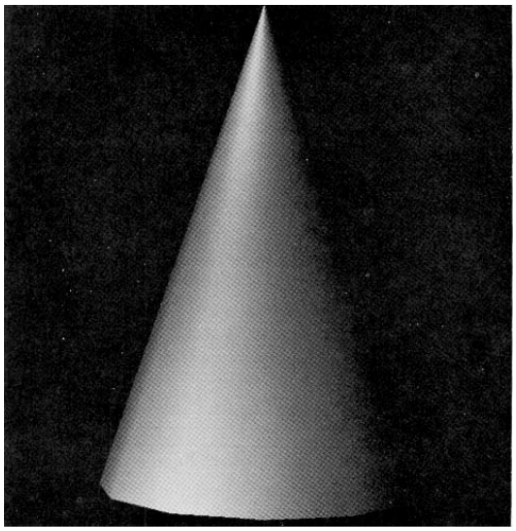


图 8 用改进的明暗处理绘制图 1 的圆锥。

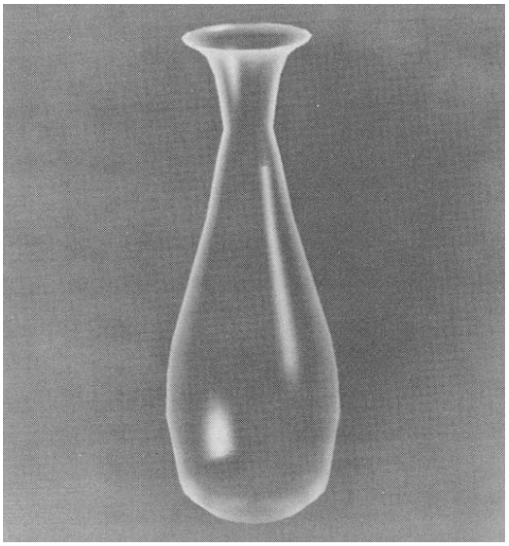


图 9 用改进的明暗处理绘制图 2 的物体。

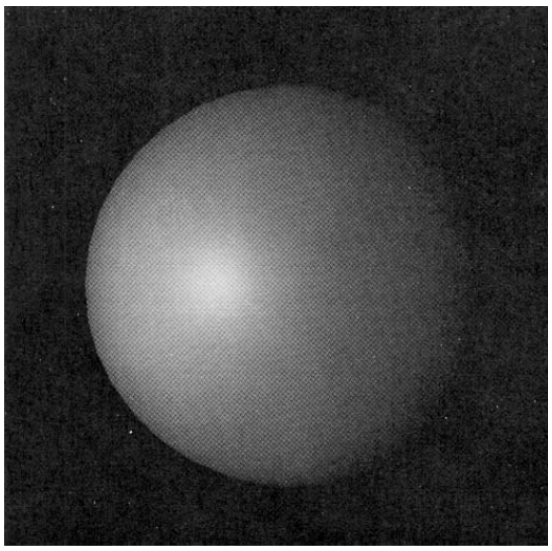


图 10(a) 新方法绘制的球体。

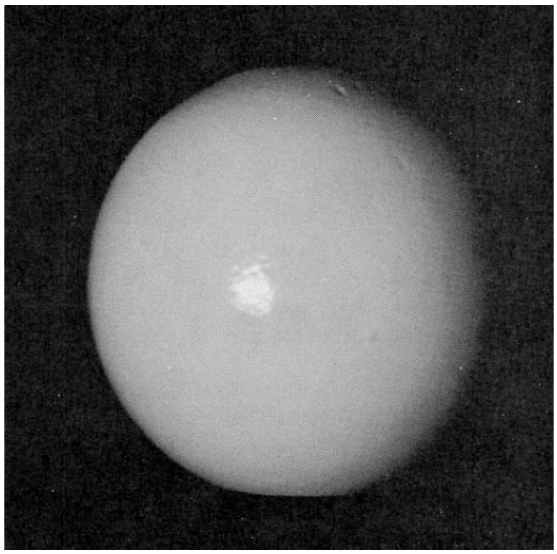


图 10(b) 真实球体的照片。

结论

本文使用线性插值来近似法线方向，但这并不能保证跨过多边形模型某条边时，明暗函数的一阶导数连续。在极端情况下，如果两个相邻多边形沿共同边的朝向发生突然变化，马赫带效应引起的主观亮度变化仍会沿该边显现。不过，与 Gouraud 平滑明暗处理相比，这种效应在本文模型中明显不那么突出。

前面关于马赫带效应的讨论还指出一个有趣的事实：只要强度分布曲线的斜率发生较大变化，即使曲线的一阶导数是连续的，也仍可能看见这一效应。采用更高次数的插值曲线，可以使边缘的存在变得难以察觉，不过仍会产生一定的马赫带效应。

在比较使用不同明暗处理技术生成的同一物体图像时，研究发现：新方法生成的图像，与使用三次插值曲线进行明暗计算得到的图像相比，差别不大。另外，对于动态画面的实时显示系统，时间至关重要。考虑到当时计算高次插值函数系数的技术水平，使用高次插值曲线似乎尚不可行。

如果用硬件实现本文的明暗模型，当然需要比简单的 Gouraud 方法更多的硬件。Gouraud 模型只需要一个用于明暗函数的插值器；它必须为每个光栅单位计算一个新的明暗值，因此速度必须非常高，才能驱动实时显示。

本文提出的模型则需要三个并行工作的插值器。此外，由于插值结果并不是单位向量，而式（6）、式（7）以及结论中所称的式（8）需要单位法线，因此还需要额外的硬件将插值器的输出“归一化”。这要求一种非常快速的平方根计算机制。

这些问题都并非过于困难。考虑到新模型带来的图像质量提升，在实时显示很重要的应用中，花费额外的硬件成本很可能是值得的。

原文末尾标注“Received November 1975; revised March 1975”（收稿时间晚于修订时间），按原刊照录；日期次序疑有排印错误。原文最后一组反射分量关系式未印出“（8）”编号，但结论中确实引用了“式（8）”。

参考文献

以下保留原文献的英文题名、作者、刊物和年份，便于进一步查找。

1. MAGI, Mathematical Applications Group Inc. “3-D simulated graphics.” Datamation 14 (Feb. 1968), 69.

2. Comba, P. G. “A procedure of detecting intersections of three-dimensional objects.” Rep. 39,020, IBM New York Scientific Center, Jan. 1967.

3. Weiss, R. A. “BE VISION, a package of IBM 7090 FORTRAN programs to draw orthographic views of combinations of plane and quadric surfaces.” Journal of the ACM 13(2), Apr. 1966, 194–204.

4. Mahl, R. “Visible surface algorithm for quadric patches.” IEEE Transactions C-21, Jan. 1972, 1–4.

5. Catmull, E. E. “A subdivision algorithm for computer display of curved surfaces.” Ph.D. thesis, Department of Computer Science, University of Utah.

6. Sutherland, I. E., Sproull, R. F., and Schumacker, R. A. “A characterization of ten-hidden surface algorithms.” Computing Surveys 6, Mar. 1974, 1–56.

7. Bui Tuong Phong and Crow, F. C. “Improved rendition of polygonal models of curved surfaces.” To be presented at the joint USA–Japan Computer Conference.

8. Warnock, J. E. “A hidden-line algorithm for halftone picture representation.” Department of Computer Science, University of Utah, TR 4-15, 1969.

9. Watkins, G. S. “A real-time visible surface algorithm.” Department of Computer Science, University of Utah, UTEC-CSc-70-101, June 1970.

10. Newell, M. E., Newell, R. G., and Sancha, T. L. “A new approach to the shaded picture problem.” Proceedings of ACM 1973 National Conference.

11. Gouraud, H. “Computer display of curved surfaces.” Department of Computer Science, University of Utah, UTEC-CSc-71-113, June 1971. Also in IEEE Transactions C-20, June 1971, 623–629.

版权与翻译说明

原论文版权：© 1975 Association for Computing Machinery, Inc. 本中文版依据用户提供的原论文制作，保留学术出处，供个人阅读与研究使用。中文表述为译文，原始英文排印的图片和参考文献仍保留以便核对。